

Wyniki zadania.

Zaimplementowane zostały dwa modele sekwencyjne.

model_simple - podstawowy model z jedną warstwą ukrytą:


- Wejście (13)
- Warstwa ukryta - 32 neurony, funkcja aktywacji ReLu, domyślna inicjalizacja wag, czyli GlorotUniform
- Wyjście - 3 neurony, aktywacja Softmax, dla klasyfikacji na 3 kategorie

model_complex - bardziej eksperymentalny/złożony model:


- Wejście (13)
- Pierwsza warstwa ukryta - 64 neurony, funkcja aktywacji ELU, inicjalizacja GlorotUniform
- Dropout ustawiony na 0.3
- Druga warstwa ukryta - 32 neurony, aktywacja ReLu, wagi HeNormal
- Wyjście - 3 neurony, aktywacja Softmax, dla klasyfikacji na 3 kategorie

Obydwa modele były trenowane przez 50 epok z loss rate ustawionym na 0.001, a trening był powtórzony parę razy.

Krzywa uczenia dla modelu - model_simple



Krzywa uczenia dla modelu - model_complex



Model simple, szybko się uczy, dokładność rośnie bardzo szybkim tempem do około 10 epoki, następnie znacząco spowolnia. Krzywe accuracy dla zbioru train/validation są na tym samym poziomie. Krzywe loss również zbierają do niskich, jednakowych wartości. Model wykazuje się świetnym procesem uczenia, dobrą generalizacją i braku overfittingu.

Model - model_simple - Test Loss: 0.0352, Test Accuracy: 1.0000

Model complex, osiąga wzrost szybciej niż model simple, jednak jest widoczna różnica pomiędzy krzywymi treningowymi i walidacyjnymi. Dokładność

treningowa osiąga poziom 1.0, ale walidacyjna jest już ~ 0.97 . Widoczny overfitting.

Model - model_complex - Test Loss: 0.0296, Test Accuracy: 0.9722

Wnioski:

Lepiej sprawdził model_simple - wyższa stabilność, acc na poziomie 100%. Kluczowym czynnikiem wydają się złożoność modelu do wielkości danych. Nasz zestaw jest dosyć mały, a model complex, posiadający o wiele większą ilość parametrów, neuronów, jest zbyt złożony na taką ilość dostarczonych danych. Mimo zastosowania dropoutu, by zdezaktywować część neuronów, doszło do przeuczenia. Model model_simple, w swojej konfiguracji posiadał odpowiednią pojemność, by doskonale nauczyć się wzorców danych, a jednocześnie nie doprowadzić do zapisania szumu.