

Wyniki zadania.

Zaimplementowane zostały dwa modele sekwencyjne.

model_simple - podstawowy model z jedną warstwą ukrytą:


- Wejście (13)
- Warstwa ukryta - 32 neurony, funkcja aktywacji ReLu, domyślna inicjalizacja wag, czyli GlorotUniform
- Wyjście - 3 neurony, aktywacja Softmax, dla klasyfikacji na 3 kategorie

model_complex - bardziej eksperymentalny/złożony model:


- Wejście (13)
- Pierwsza warstwa ukryta - 64 neurony, funkcja aktywacji ELU, inicjalizacja GlorotUniform
- Dropout ustawiony na 0.3
- Druga warstwa ukryta - 32 neurony, aktywacja ReLu, wagi HeNormal
- Wyjście - 3 neurony, aktywacja Softmax, dla klasyfikacji na 3 kategorie

Obydwa modele były trenowane przez 50 epok z loss rate ustawionym na 0.001

Krzywa uczenia dla modelu - model_simple



Krzywa uczenia dla modelu - model_complex



Model - model_simple - Test Loss: 0.1160, Test Accuracy: 0.9444

Model - model_complex - Test Loss: 0.0329, Test Accuracy: 0.9722

Model simple, szybko się uczy, dokładność rośnie bardzo szybkim tempem do około 10 epoki, następnie znacząco spowolnia. Training acc osiąga ~1.0, a val acc poziom ~0.95. Loss rate bardzo szybko również opada na początku, val loss jest trochę wyższy od train lossu, - niewielkie dopasowania. Widoczny lekki

overfitting, ale generalnie model uogólnia bardzo dobrze i bardzo wysoką dokładność

Model - model_simple - Test Loss: 0.1125, Test Accuracy: 0.9722

Model complex podobnie, osiąga szybki wzrost w pierwszych praktycznie już 5 epokach, w przeciwieństwie jednak do modelu pierwszego, Train accuracy nie jest stabilnie (koniec końców jest ~ 1.0)., val acc nieco wyższy ~ 0.97 . Train loss szybko spada na poziom ~ 0.08 , a val loss stabilizuje się na poziomie podobnym ~ 0.10 . Widoczny też overfitting ale łagodniejszy niż w simple modelu.

Model - model_complex - Test Loss: 0.0879, Test Accuracy: 0.9722

Wnioski:

Lepiej sprawdził model_complex - większą pojemność, lepszy aktywacje i inicjalizatory oraz regulacja Dropout. Mniejszy test loss - pewniejsze przewidywania oraz lepsze wyniki walidacji. Jednak przy tak małej ilości danych, może to być też efekt losowości. Warto powtórzyć trening wielokrotnie z różnymi seedami lub bez dropoutu.